UNIVERSIDAD DE GRANADA

INTELIGENCIA DE NEGOCIO

JANUARY 29, 2021

Detección de anomalías

David Alberto Martín Vela

davidmv1996@correo.ugr.es
Doble Grado Ingeniería Informática y Matemáticas

Curso 2020-2021

Contents

Descripción y análisis del problema

¿Alguna vez nos hemos preguntado como los bancos detectan fraudes o en las redes sociales cuando sospechan que un inicio de sesion es fraudulento? Esto se realiza principalmente a través del proceso denominado Detección de anomalías (*Anomaly Detection*).

Una anomalía, por definición, es algo que se desvía de lo que es estándar, normal o esperado. La detección de anomalías o la detección de valores atípicos es el proceso de identificación de elementos raros, observaciones, patrones, valores atípicos o anomalías que diferirán significativamente de los elementos o patrones normales. Las anomalías a veces se denominan valores atípicos, novedades, ruido, desviaciones o excepciones.

Se dice que la información es poder, y cada vez se tiene más en cuenta que esa información en la sociedad actual viene dada por los datos. Ahora bien, una gran cantidad de datos conlleva poder si se manejan correctamente.

Según un artículo de Forbes [For] el **61%** de los vendedores planean usar el aprendizaje automático como parte de su estrategia de datos, dado que todavía hay empresas que se están perdiendo esta ventaja con el resto de los competidores. Se remarca el hecho de que, entre otros, pueden ayudar a descubrir palabras clave y otros elementos de las campañas de marketing que no se están aprovechando, prevenir las violaciones y amenazas a la seguridad y detectar amenazas y problemas antes de que causen daños.

En el mismo estudio de Forbes se menciona el caso de la empresa de consultoría Accenture. Casi el **10%** de sus 25 millones de procesos anuales de líneas de gastos estaban siendo marcados por incumplimiento o fraude. Mientras que su sistema basado en reglas funcionaba hasta cierto punto, Accenture implementó un algoritmo de aprendizaje automático para optimizar el proceso. Se utilizó para reducir los falsos positivos, detectar los valores anómalos y crear una solución no supervisada.

Por supuesto es difícil saber que pasa exactamente con los datos, pero es ahí donde entra la inteligencia artificial. Herramientas como por ejemplo Google Analytics, Facebook Ads y Shopify no son capaces de abordar todos los datos en grandes empresas. Y es aquí donde un negocio debe apostar por mecanismos de detección de anomalías con algoritmos de aprendizaje automático.

Al principio para orientar esta práctica alternativa a un tema específico, las primeras dos opciones que se me venían a la cabeza eran dos áreas del conocimiento, una primera opción, **la detección de terremotos**, debido a la gran cantidad de los mismos ocurrido últimamente en Granada [Ter], y otra opción, detección de anomalias en el campo de la bolsa, debido otro acontecimiento reciente donde **GameStop se**

dispara en bolsa tras la compra de acciones de usuarios de Reddit [Red].

Planteamiento del problema

Un resumen rápido de esta situación [Pic] es que un grupo de inversores decidió apostar fijo por la caída de las acciones de GameStop sin arriesgarse, pues esta tienda llevaba perdiendo en bolsa desde bastante tiempo principalmente por el auge de las ventas digitales frente al formato físico. De esta forma, acordaron vender sus acciones a un precio fijo dentro de un periodo de tiempo determinado dando por sentado que las acciones de la tienda seguirían cayendo y deseando así que las acciones cayeran para obtener beneficio.

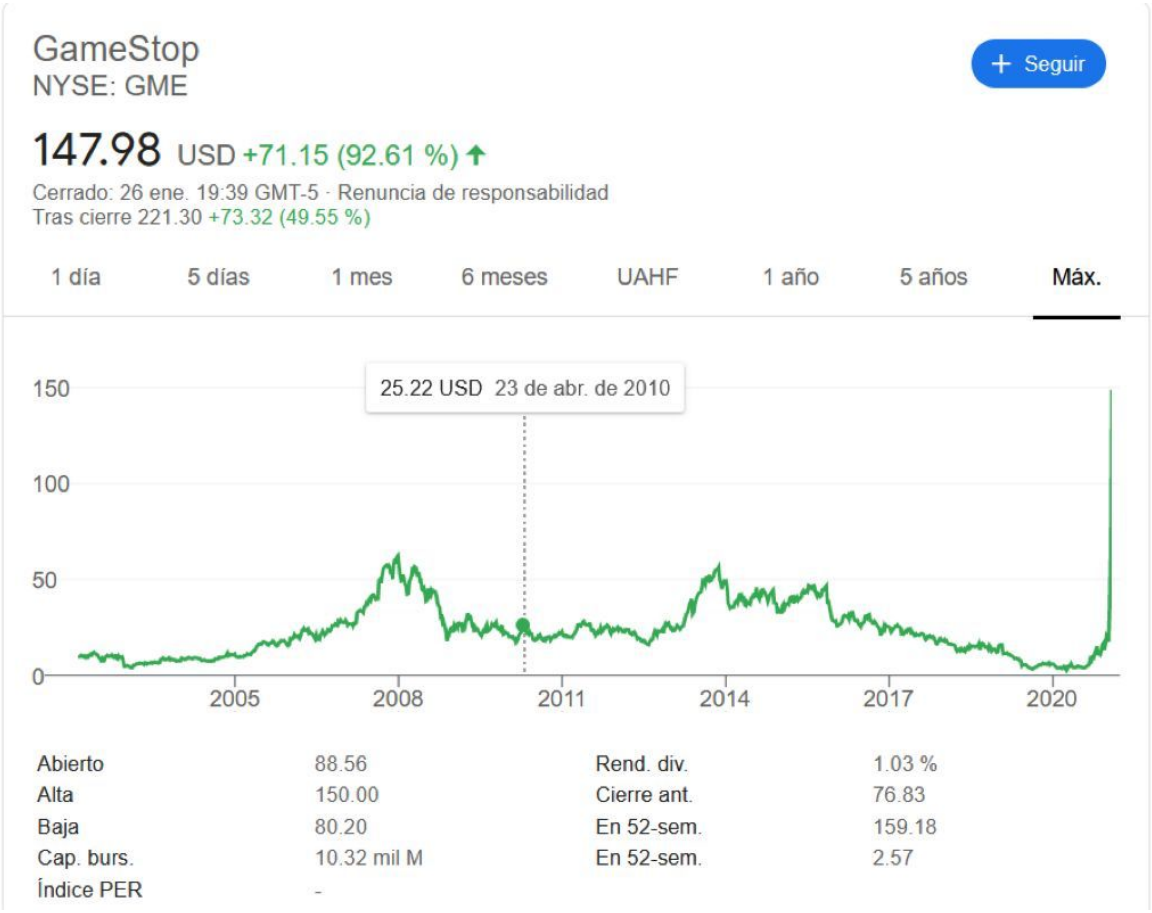

Figure 1: Gamestop stock from the last days

Sin embargo, esta estrategia llegó a oídos de los miembros del subreddit *wallstreetbets*, a quienes les pareció mal cómo se estaban comportando estos inversores. Decidieron tomar la decisión de comprar estas acciones baratas, inflando rápidamente el valor mucho más allá de lo que esperaban los administradores de fondos de cobertura, de manera que algunos miembros de Reddit han llegado a pagar miles de dólares con el objetivo de reventar los planes de los inversores mencionados anteriormente [1]. Mientras que *wallstreetbets* celebran la locura y dicen que no van a

vender y seguir comprando (incluso hay gente que compro hace año y medio una call con 50k y si la ejecuta se llevaría 36 millones ahora mismo) [Cal]. Ahora los compradores de Reddit deben calcular cuándo vender sus acciones para obtener beneficio, el cual podría ser de hasta 3.000 veces lo que compraron. Además, están explorando otros informes de **AMC** y **BlackBerry**, una cadena de cines estadounidense y una empresa de tecnología canadiense, para llevar a cabo acciones similares. **Otro tema interesante podría ser que debido a este fenómeno hay gente aplicando análisis de opiniones/sentimientos** en este foro de reddit para ver cuál puede ser el próximo objetivo pero esto ya se sale de nuestro tema elegido que es la detección de anomalias.

Para los datos, vamos a utilizar el paquete *pandas-datareader* [Pan] [1] donde extraeremos los datos trading volume data de Yahoo Finance. En nuestro caso, nuestras características de entrada serán una lista de símbolos ETF, los comentados anteriormente que corresponderán a Gamestop (GME), Blackberry (BB), Nokia (NOK) y AMC. Definiremos este entorno como nuestro "mercado", aunque en la práctica podríamos hacer que sea mucho, mucho más grande. Cogemos fechas desde hace 5 años hasta hoy, donde han ocurrido los acontecimientos recientes. Mostramos imagenes del trading volume y del precio de cierre en la figuras [2] y [3] respectivamente.

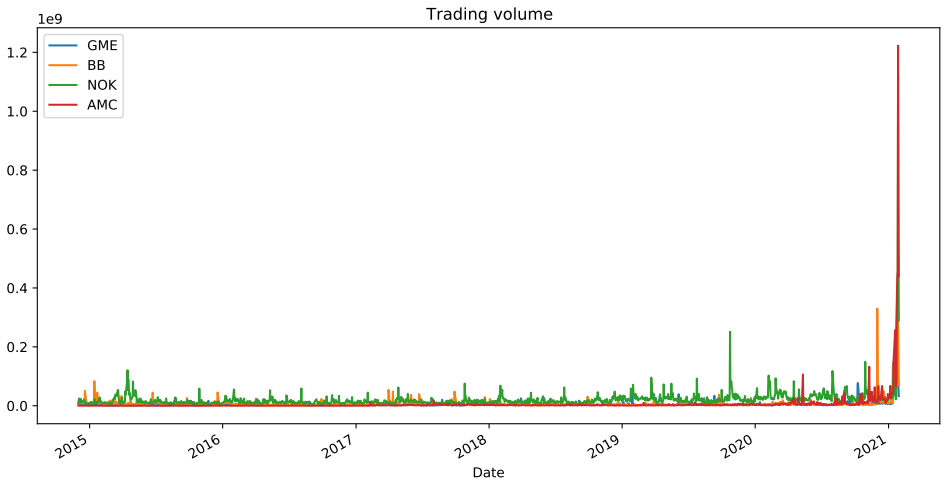

Figure 2: Trading volume data

[1] The Pandas datareader is a sub package that allows one to create a dataframe from various internet datasources, currently including: Yahoo! Finance. Google Finance.

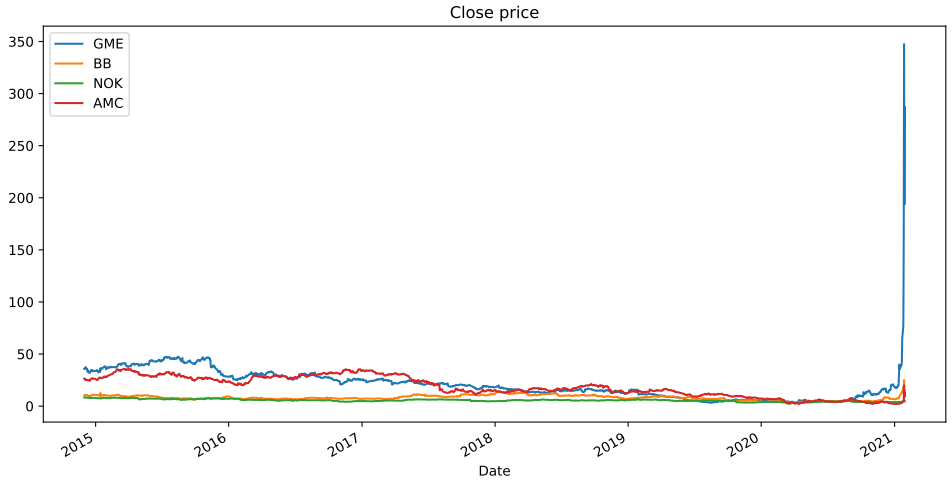

Figure 3: Closing Price

En el comercio como en la vida, a menudo es extremadamente valioso determinar si el entorno actual es anómalo o no de alguna manera. Si las cosas están actuando ”normalmente”, sabemos que nuestras estrategias pueden operar de cierta manera. Por ejemplo, si nos encontramos en un entorno comercial normal, podríamos emplear una estrategia de volatilidad en corto. Por otro lado, si identificamos que estamos en un mercado anormalmente emocionante, podría ser necesario emplear una estrategia que haga exactamente lo contrario: buscar oportunidades para el comercio basado en el impulso, por ejemplo. En ese tipo de mercado, acortar la volatilidad podría ser muy peligroso. El objetivo será aplicar una serie de algoritmos para determinar cuándo el volumen de operaciones de nuestra lista de símbolos se encuentra en un estado anómalo. Esto podría significar, por ejemplo, que estamos detectando un pico en el volumen de operaciones.

Descripción de los algoritmos

Vamos a utilizar y comparar algoritmos de las bibliotecas PyOD [Pyob] y Scikit-Learn Outlier Detection [Skl], primero, vamos a comentar algunos de ellos. El módulo Python Outlier Detection (PyOD) facilita el modelado de detección de anomalías. Recopila una amplia gama de técnicas que van desde el aprendizaje supervisado hasta las técnicas de aprendizaje no supervisado. No es necesario probar todas las técnicas para encontrar anomalías. Dependiendo de los datos, algunas técnicas funcionan mejor que otras. Típicamente el problema de detección de anomalías es un problema no supervisado, esto quiere decir que nuestros algoritmos no tienen etiquetas para entrenar. No obstante tenemos aproximaciones de algoritmos supervisados para este tipo de problemas, aunque debido al conjunto de datos que hemos elegido donde tenemos un problema de aprendizaje no supervisado (cluster) donde intentaremos aprender el patrón de lo datos pero no mediante conjuntos de entrenaimiento sino por esta demasiado lejos de un grupo, directamente sobre el conjunto aplicamos las ténicas, luego es un problema no supervisado donde nos centraremos principalmente en algoritmos no supervisados de las librerias comentadas anteriormente.
Los algoritmos que probaremos algoritmos no supervisados han sido escogidos de la documentación de PyOD [Lis] y son los siguientes:

1. **Linear Models for Outlier Detection**

   (a) **PCA**: Principal Component Analysis es una reducción de dimensionalidad lineal que utiliza la descomposición de valores singulares de los datos para proyectarlo a un espacio dimensional inferior. Aunque tiene una gran cantidad de usos nosotros vamos a centrarnos en detección de anomalías.

   En este procedimiento, la matriz de covarianza de los datos se puede descomponer en vectores ortogonales, llamados autovectores, asociados con autovalores. los vectores propios con valores propios altos capturan la mayor parte de la varianza en el datos.

   Por lo tanto, un hiperplano de baja dimensión construido por k autovectores puede capturar la mayor parte de la varianza en los datos. Sin embargo, los valores atípicos son diferentes de puntos de datos normales, que es más obvio en el hiperplano construido por los autovectores con pequeños autovalores.

   Por lo tanto, los valores anomalos buscados se pueden obtener como la suma de los valores proyectados distancia de una muestra en todos los vectores propios y la puntuación será la suma de la distancia euclidiana

ponderada entre cada muestra y la hiperplano construido por los autovectores seleccionados.

(b) **Minimum Covariance Determinant (MCD)** (use the mahalanobis distances as the outlier scores). Es un estimador robusto de covarianza.

Se aplicará el estimador de covarianza determinante de covarianza mínima en datos distribuidos en gauss, pero aún podría ser relevante en datos extraído de una distribución simétrica unimodal. No está destinado a ser utilizado con datos multimodales (el algoritmo utilizado para ajustar un objeto MinCovDet es probable que falle en tal caso). Se deben considerar métodos de búsqueda de proyecciones para hacer frente a multimodales conjuntos de datos.

Primero se ajusta un modelo determinante de covarianza mínima y luego calcule el Distancia de Mahalanobis como el grado atípico de los datos

(c) **One-Class Support Vector Machines (OCSVM)**. Ya hemos visto en clase este tipo de modelos, solo que en este caso se plantea otra funcionalidad. Detección de valores atípicos sin supervisión esstimando el soporte de una distribución de alta dimensión. La implementación se basa en libsvm de Sklearn aunque utilizaremos el algoritmo de PyOD.

2. **Proximity-Based Outlier Detection Models**

(a) **Local Outlier Factor (LOF)** La puntuación de anomalía de cada muestra se denomina Factor de valor atípico local (LOF). Mide la desviación local de densidad de una muestra dada con respeto a sus vecinos, es local en el sentido de que la puntuación de anomalía depende de qué tan aislado esté el objeto es con respecto al vecindario circundante. Más precisamente, la localidad está dada por k vecinos más cercanos, cuya distancia se utiliza para estimar la densidad local. Comparando la densidad local de una muestra con las densidades locales de sus vecinos, uno puede identificar muestras que tienen un sustancialmente menor densidad que sus vecinos. Estos se consideran valores atípicos.

(b) **Clustering-Based Local Outlier Factor (CBLOF)** CBLOF toma como entrada el conjunto de datos y el modelo de clúster que se generado por un algoritmo de agrupamiento. Clasifica los grupos en pequeños clústeres y clústeres grandes utilizando los parámetros alfa y beta. Luego, la puntuación de anomalía se calcula en función del tamaño del clúster punto al que pertenece, así como la distancia al cúmulo grande más cercano.

Utiliza la ponderación para el factor de valores atípicos en función de los tamaños de los grupos como propuesto en la publicación original. Dado que esto puede llevar a comportamiento (no se encuentran valores atípicos cercanos a grupos pequeños), está deshabilitado Las puntuaciones de Outliers se calculan únicamente en función de su distancia a el centro grande más cercano.

De forma predeterminada, kMeans se utiliza para el algoritmo de agrupación en clústeres en lugar de Algoritmo Squeezer mencionado en el

artículo original por múltiples razones.

(c) **k Nearest Neighbors (kNN)** De nuevo, ya hemos visto este tipo de algoritmo en la asignatura, solo que en este caso se usa la distancia al kth vecino más cercano como puntuación de anomalía.

(d) **Median kNN Outlier Detection** Igual que antes solo que utilizando la median distance.

(e) **Histogram-based Outlier Score (HBOS)** es un algoritmo es un eficiente sin supervisión. Asume la independencia de la función y calcula el grado de las anomalías mediante la construcción de histogramas.

3. **Probabilistic Models for Outlier Detection**

(a) **Angle-Based Outlier Detection (ABOD)** Considera la relación entre cada punto y su (s) vecino (s). No considera las relaciones entre estos vecinos. La varianza de sus puntuaciones de coseno ponderadas a todos los vecinos podría verse como la puntuación periférica. Funciona bien en multidimensional data.

4. **Outlier Ensembles and Combination Frameworks**

(a) **Isolation Forest** Utiliza la biblioteca scikit-learn internamente. En este método, la partición de datos se realiza mediante un conjunto de árboles. Isolation Forest proporciona una puntuación de anomalía al observar qué tan aislado está el punto en la estructura. Luego, la puntuación de anomalía se utiliza para identificar valores atípicos de observaciones normales Isolation Forest funciona bien en datos multidimensionales

(b) **LSCP** LSCP es un conjunto de detección de valores atípicos paralelo no supervisado que selecciona detectores competentes en la región local de una instancia de prueba. Esta La implementación utiliza una estrategia de Promedio de Máximo *(Average of Maximum)*. Primero, un heterogéneo La lista de detectores base se ajusta a los datos de entrenamiento y luego genera un la verdad pseudo-terrestre para cada instancia de tren es generada por tomando la puntuación máxima de valores atípicos.

Para cada instancia de prueba:

i. La región local se define como el conjunto de puntos de entrenamiento más cercanos en subespacios de características muestreados aleatoriamente que ocurren con más frecuencia que un umbral definido en múltiples iteraciones.

ii. Usando la región local, se define una verdad de pseudo terreno local y la La correlación de pearson se calcula entre el entrenamiento de cada detector base puntajes atípicos y la verdad pseudo fundamental.

iii. Se construye un histograma a partir de las puntuaciones de correlación de Pearson; detectores en los contenedores más grandes se seleccionan como detectores de base competentes para el instancia de prueba.

iv. Se toma la puntuación promedio de valores atípicos de los detectores competentes seleccionados para ser la puntuación final.

Para configurar estos algoritmos utilizaremos el parámetro contamination [2].

[2]The amount of contamination of the data set, i.e. the proportion of outliers in the data set. Used when fitting to define the threshold on the decision function.

Estudio experimental

Todo lo relacionado con esta parte de la práctica puede encontrarse en mi repositorio de **github**.

Vamos a proceder a aplicar los algoritmos anteriores con el dataset comentado en la descripción del problema, 3104 instancias recogidas en el periodo de tiempo que va desde el 1 de dicembre de 2014 hasta hoy, 1 de febrero. En las figuras [2] y [3]. Inicialmente hagamos un describe para ver los datos en la tabla [1]

	GME	BB	NOK	AMC
count	1.047000e+03	1.047000e+03	1.047000e+03	1.047000e+03
mean	5.781856e+06	7.729197e+06	2.394326e+07	8.067518e+06
std	1.296132e+07	2.352192e+07	4.480880e+07	4.861418e+07
min	9.729000e+05	1.054900e+06	3.136300e+06	1.802000e+05
25%	2.257900e+06	2.954850e+06	1.197440e+07	1.430500e+06
50%	3.215900e+06	3.960900e+06	1.817230e+07	2.155200e+06
75%	5.204550e+06	6.122550e+06	2.613805e+07	3.928200e+06
max	1.967843e+08	3.722226e+08	1.123003e+09	1.222342e+09

Table 1: Describe

El campo es bastante complejo, a priori nuestro dataset depende del tiempo, en general los datos financieros son procesos estocásticos ya que tenemos la variable del tiempo, al obviar el factor del tiempo no estamos teniendo en cuenta algo muy importante, también habría que ver que definimos con un pico u outlier, una subida muy alta de la cotización de los retornos? Puede que este tipo de cosas sea cíclicas y normales respecto a la serie del tiempo. Para facilitar el tema elegido simplemente aplicaremos los algoritmos sobre un atributo o sobre ambos para facilitar la comparación y visualización y comentar los resultados.
En general nuestra serie temporal de volumen tiene picos significativos en el volumen de operaciones en nuestros ETF elegidos. Algunos eventos notables incluyen la caída repentina del Tesoro de octubre de 2014, el aumento de la volatilidad en agosto de 2015, así como la elección de Donald Trump a fines de 2016. Nótese la relativa calma a principios de 2017 ...
Si bien estos eventos son obvios a simple vista (mucho después del hecho), lo que sería útil es la capacidad de clasificar automáticamente los eventos basándose

únicamente en los datos del volumen de operaciones, es decir, sin el uso de un ser humano. Este es el objetivo del aprendizaje automático y, afortunadamente, este es exactamente el tipo de caso de uso para utilizar nuestros algoritmo.

Inicialmente creo que es necesario trabajar con un ejemplo simple de método de detección de anomalías con una variable únicamente en el que detectamos valores atípicos a partir de una distribución de valores en un solo espacio de características. Por ello, utilizaremos únicamente los datos del atributo de **Gamestop(GME)** y vamos a encontrar patrones en volumen de trading y closing price por separado que no se ajustan al comportamiento esperado. Es decir, detectar valores atípicos para una variable a la vez.

Mostramos una pequeña visualizión inicial de nuestro conjunto de datos.

```
Skewness: 10.093959
Kurtosis: 122.632442
```

En las imagenes [4] y [5] vemos que está lejos de una distribución normal, y tiene una cola larga y delgada positiva, la masa de la distribución se concentra a la izquierda de la figura. Las distribuciónes superan con creces las colas de la distribución normal. Hay una región donde los datos tienen baja probabilidad de aparecer y está en el lado derecho de la distribución.

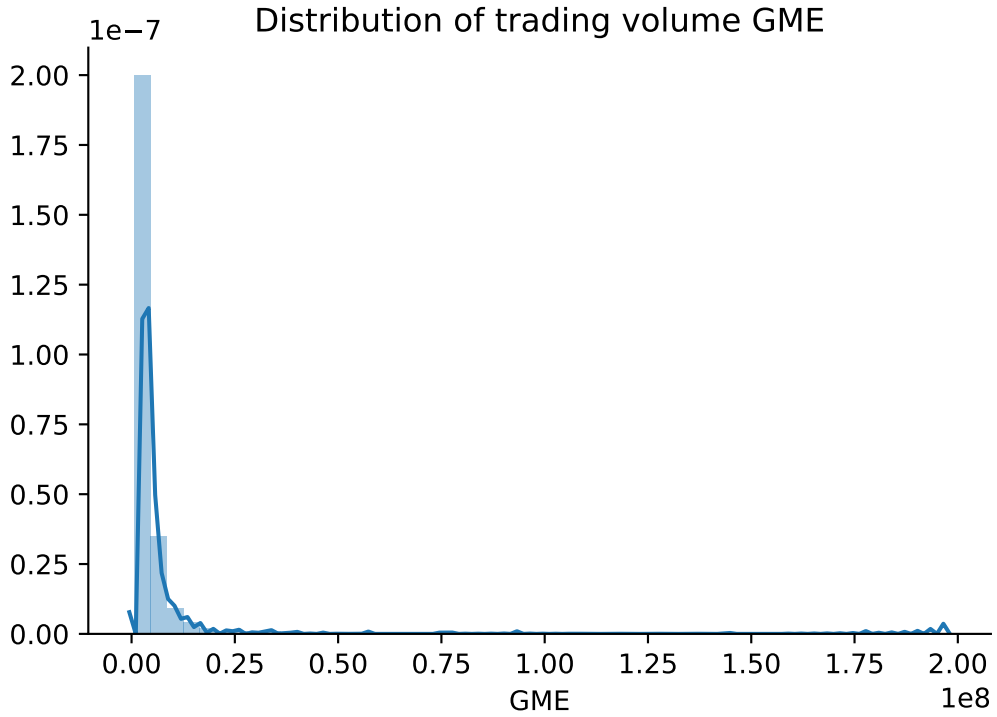

Figure 4: Distribución trading volume GME

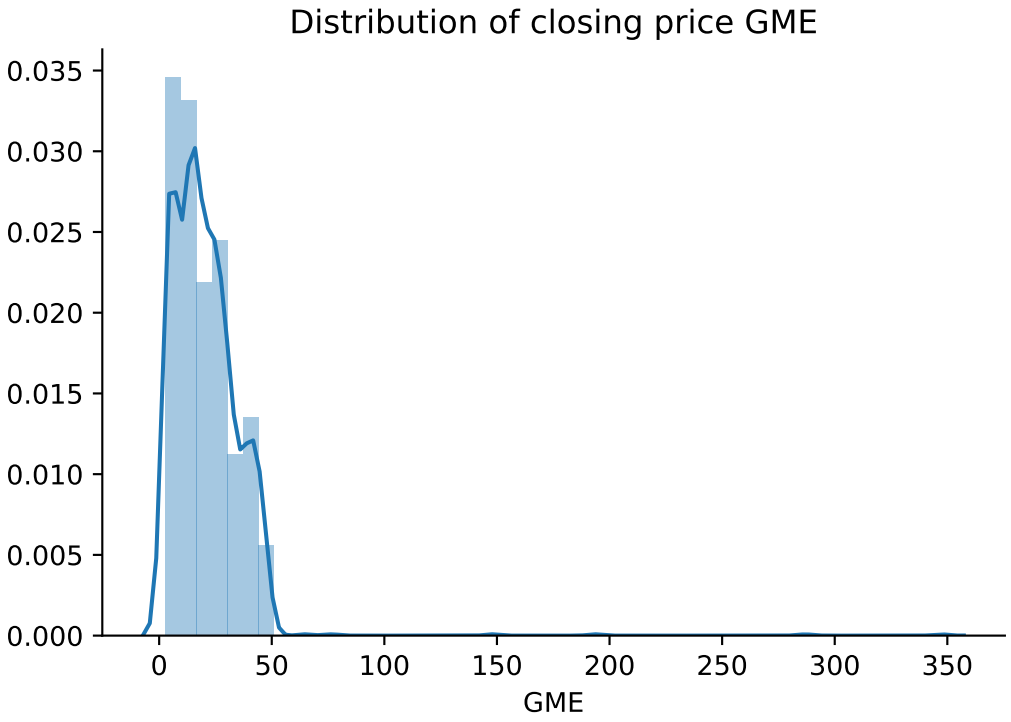

Figure 5: Distribución closing price GME

Como hemos visto antes, Isolation Forest es un algoritmo para detectar valores atípicos que devuelve la puntuación de anomalía de cada muestra utilizando el algoritmo IsolationForest que se basa en el hecho de que las anomalías son puntos de datos que son pocos y diferentes. Isolation Forest es un modelo basado en árboles. En estos árboles, las particiones se crean seleccionando primero al azar una característica y luego seleccionando un valor de división aleatoria entre el valor mínimo y máximo de la característica seleccionada. Vamos a utilizar este algoritmo que funciona para Univariate Anomaly Detection en el caso de GME.

El siguiente proceso muestra cómo se comporta IsolationForest en el caso de GME, IsolationForest entrenado usando los datos de GME. Almacenamos el valor en una matriz NumPy para usarla en nuestro modelo más adelante. Calcula la puntuación de anomalía para cada observación. La puntuación de anomalía de una muestra de entrada se calcula como la puntuación media de anomalía de los árboles en el bosque. Clasificamos cada observación como un valor atípico o no atípico. Y finalmente usamos visualización para resaltar las regiones donde caen los valores atípicos. Hemos optado por una configuración inicial a la que asignamos 100 estimadores, también destacamos que los valores de nuestros datos han sido estandarizados para unos mejores resultados de visualización y escala.

```
isolation_forest = IsolationForest(n_estimators=100)
isolation_forest.fit(volume['GME'].values.reshape(-1, 1))
```

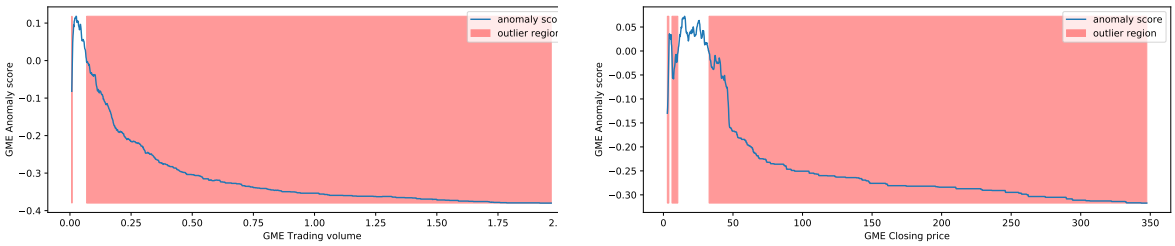

Figure 6: Isolation Forest GME

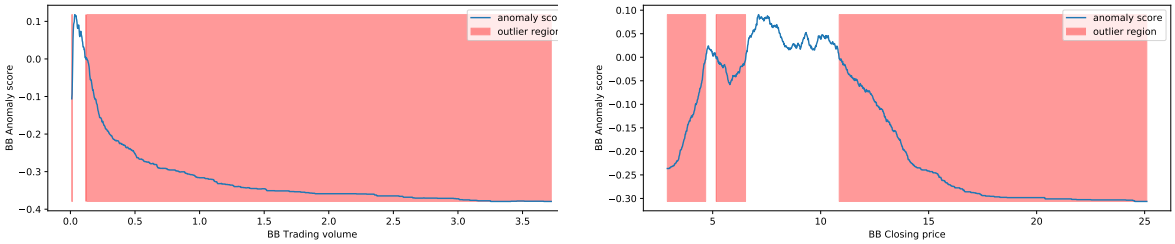

Figure 7: Isolation Forest BB

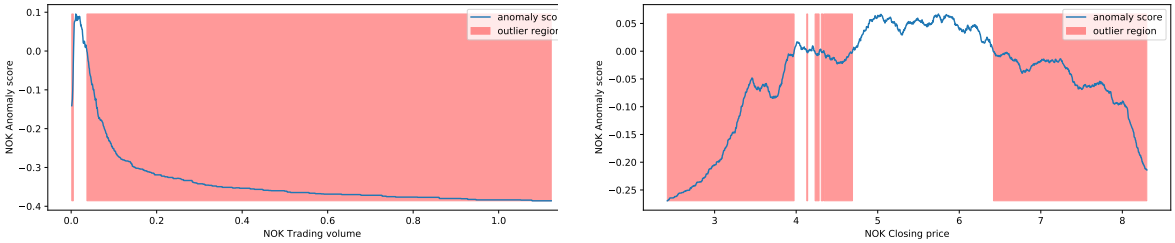

Figure 8: Isolation Forest NOK

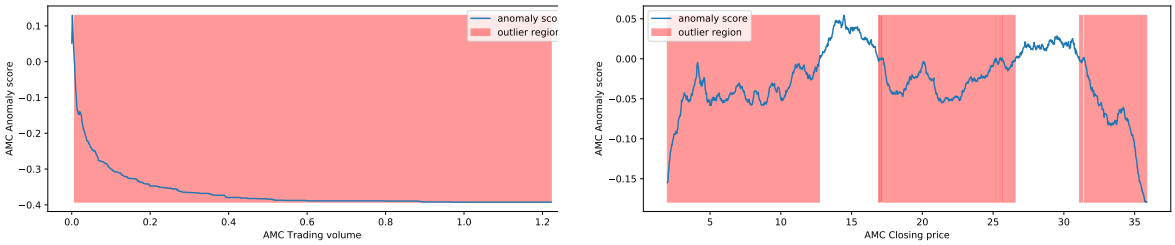

Figure 9: Isolation Forest AMC

En las imagenes de la izquiera tenemos la visualización del algoritmo con respecto el trading volume, y a la derecha respecto al closing price. Una puntuación cercana

a 1 indica anomalías. Una puntuación mucho menor que 0,5 indica observaciones normales. Si todas las puntuaciones se acercan a 0,5, entonces la muestra completa no parece tener anomalías claramente diferenciadas. Por ejemplo, en la figura de la izquierda de [6], valores por encima de 0,15 definitivamente se considera un outlier. Lo cual concuerda visualmente con la gráfica [2]. Al contrario que la imagen de la derecha donde comparado con la gráfica de la izquierda, los resultados y la visualización anteriores, parece que los beneficios que estén fuera del intervalo blanco se considerarían un valor atípico, lo cuál visualmente tiene sentido. De igual manera razonaríamos para los demás casos. Destacamos [9] donde al ser más estable la gráfica, es normal que cualquier valor que sobresalga se considere un outlier.

Nuestro modelo determinó que este periodo con una gran cantidad de trading es una anomalía. Las visualizaciones anteriores muestran las puntuaciones de anomalías y resaltan las regiones donde se encuentran los valores atípicos. Como era de esperar, la puntuación de anomalía refleja la forma de la distribución subyacente y las regiones atípicas corresponden a áreas de baja probabilidad. Sin embargo, el análisis univariante solo puede llevarnos hasta aquí. Podemos darnos cuenta de que algunas de estas anomalías determinadas por nuestros modelos no son las anomalías que esperábamos. Cuando nuestros datos son multidimensionales en lugar de univariados, los enfoques para la detección de anomalías se vuelven más intensivos desde el punto de vista computacional y más complejos matemáticamente.

La mayoría de los análisis que terminamos haciendo son multivariados debido a la complejidad del mundo en el que vivimos. En la detección de anomalías multivariadas, el valor atípico es una puntuación inusual combinada en al menos dos variables. Entonces, usando los atributos en pares , por ejemplo GME Y BB, vamos a construir un método de detección de anomalías multivariante no supervisado basado en todos los modelos comentados anteriormente.

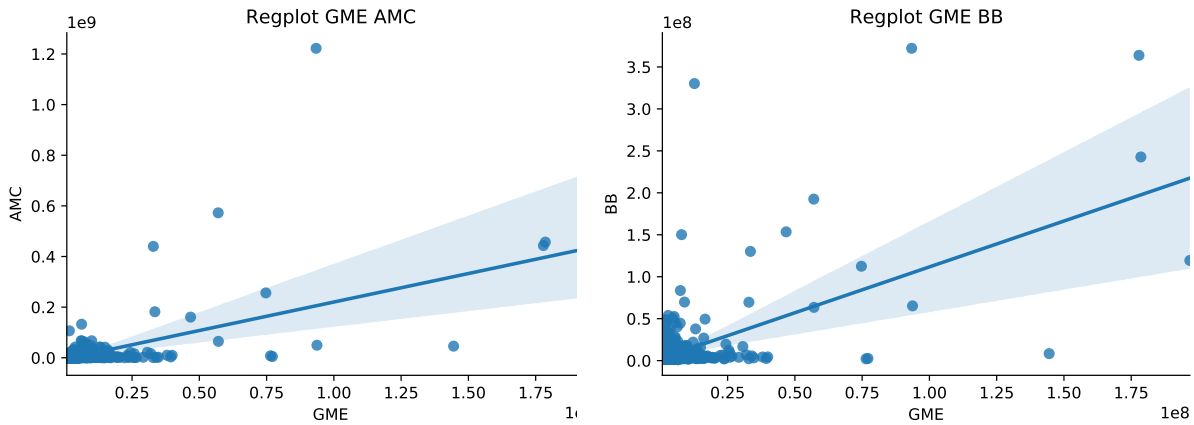

Figure 10: Regplot GME, AMC y BB

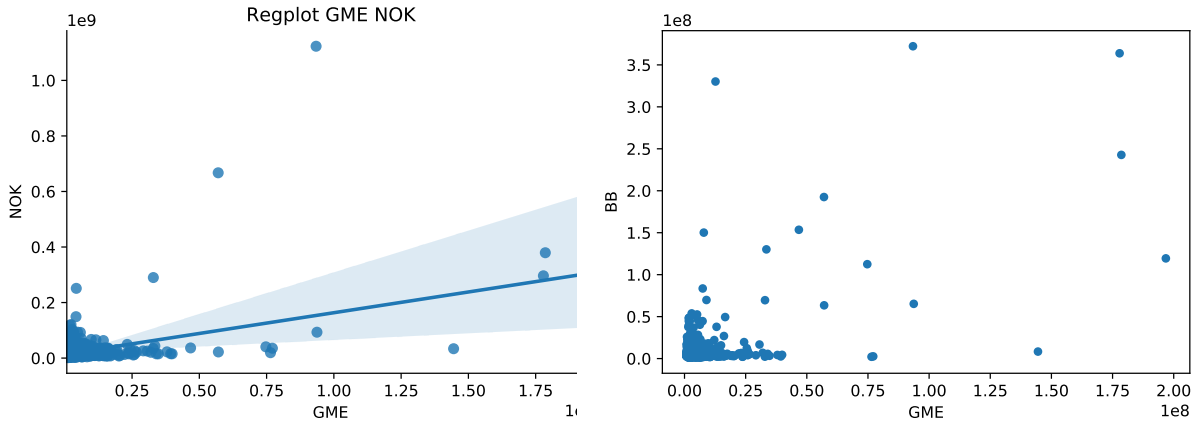

Figure 11: Regplot GME y Nokia y Scatter plot GME y BB

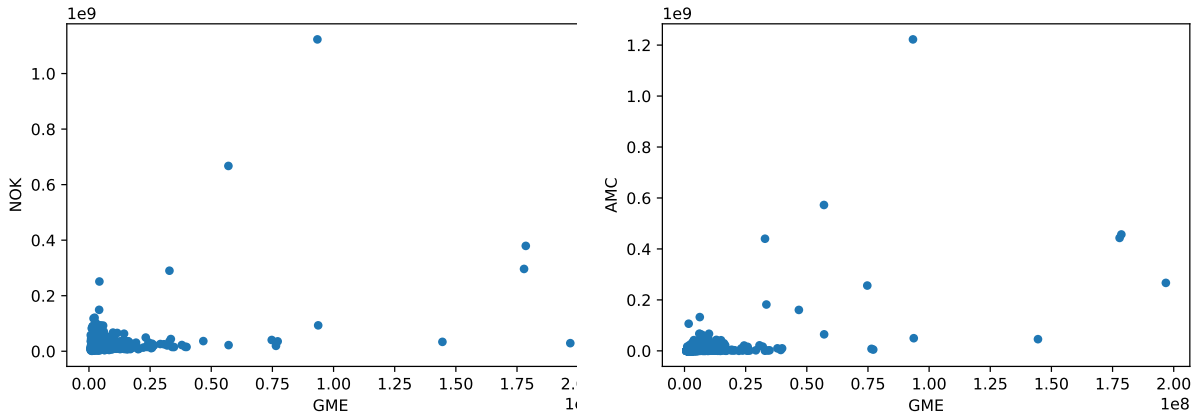

Figure 12: Regplot GME y Nokia y Scatter plot GME y BB

De las figuras de arriba vemos claramente como algunos puntos mas alejados son obviamente outliers. Como se ha comentado, realizaremos solo el ejemplo con los atributos GME y BB en pos de poder visualizar en 2D. El proceso que vamos a realizar para aplicar la tanda de algoritmos esta extraido de un ejemplo de la documentación de PyOD. [Pyoa] donde los pasos son los siguientes:

- Escalamos nuestros atributos entre 0 y 1
- Establecer una outliers fraction basandose en prueba y error, en nuestro caso 0.01
- Realizar fit del modelo y predecir con el mismo dataset ya que es un modelo no supervisado
- Utilizamos el valor de threshold para definir si un punto es inlier o outlier

- Finalmente usamos *decision_function*[3] para calcular la puntuación atípica para cada punto

Aplicamos este proceso para la lista de algoritmos comentada anteriormente.

```
random_state = np.random.RandomState(42)
outliers_fraction = 0.01
classifiers = {
        'Angle-based Outlier Detector (ABOD)':
        ABOD(contamination=outliers_fraction),
    'Cluster-based Local Outlier Factor (CBLOF)':
        CBLOF(contamination=outliers_fraction,
              check_estimator=False, random_state=random_state),
    'Histogram-base Outlier Detection (HBOS)': HBOS(
        contamination=outliers_fraction),
    'Isolation Forest': IForest(contamination=outliers_fraction,
                                random_state=random_state),
    'K Nearest Neighbors (KNN)': KNN(
        contamination=outliers_fraction),
    'Average KNN': KNN(method='mean',
                       contamination=outliers_fraction),
    'Local Outlier Factor (LOF)':
        LOF(n_neighbors=35, contamination=outliers_fraction),
    'Minimum Covariance Determinant (MCD)': MCD(
        contamination=outliers_fraction, random_state=random_state),
    'One-class SVM (OCSVM)': OCSVM(contamination=outliers_fraction),
    'Principal Component Analysis (PCA)': PCA(
        contamination=outliers_fraction, random_state=random_state),
    'Locally Selective Combination (LSCP)': LSCP(
        detector_list, contamination=outliers_fraction,
        random_state=random_state)
}
```

A continuación mostramos las áreas de resultado del proceso.

[3]Predict raw anomaly scores of X using the fitted detector. The anomaly score of an input sample is computed based on the fitted detector

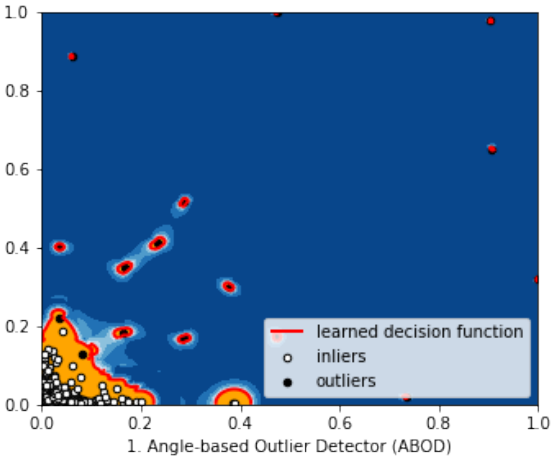

1. Angle-based Outlier Detector (ABOD)

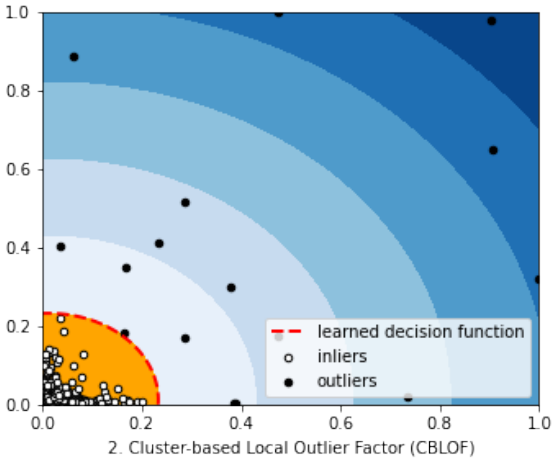

2. Cluster-based Local Outlier Factor (CBLOF)

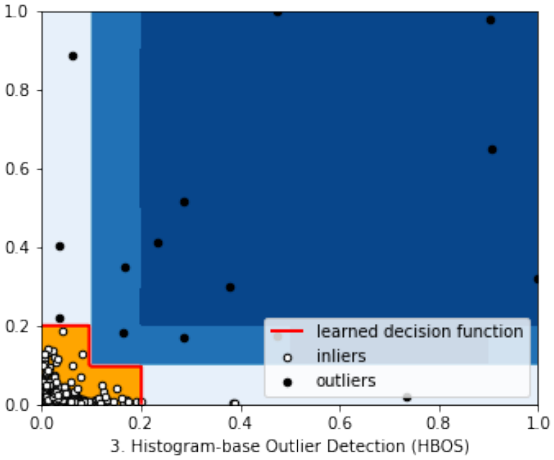

3. Histogram-base Outlier Detection (HBOS)

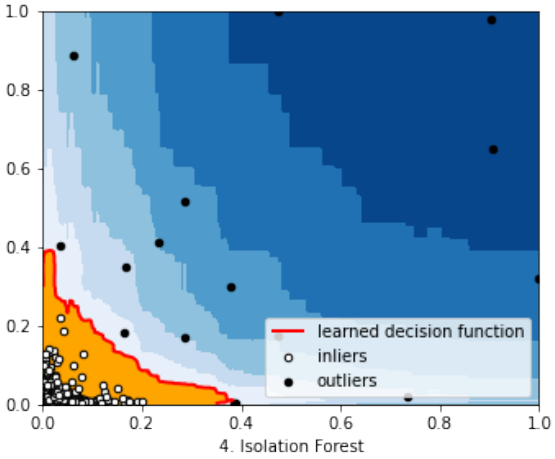

4. Isolation Forest

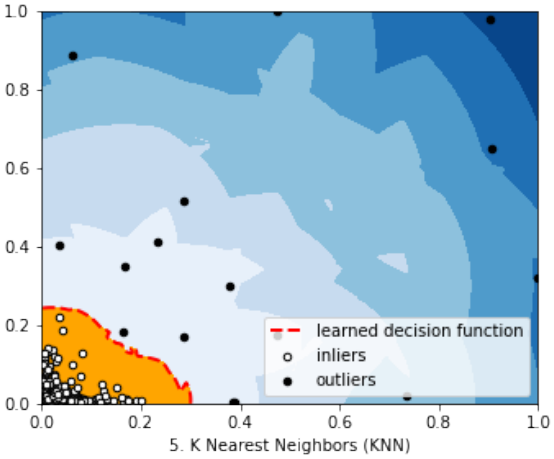

5. K Nearest Neighbors (KNN)

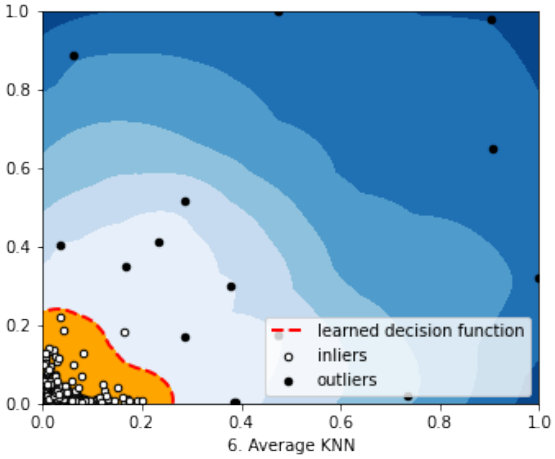

6. Average KNN

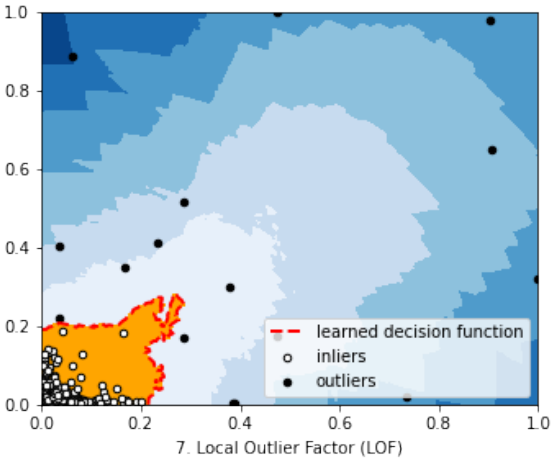

7. Local Outlier Factor (LOF)

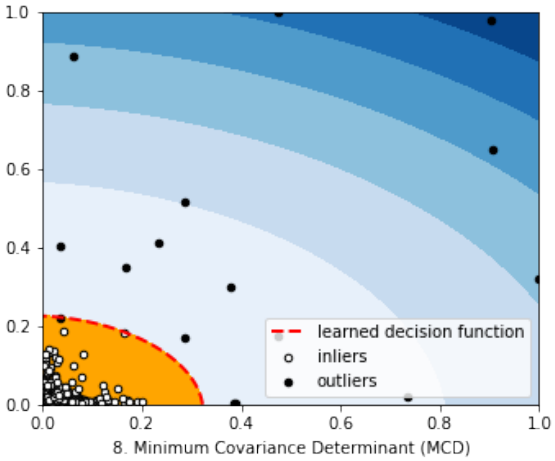

8. Minimum Covariance Determinant (MCD)

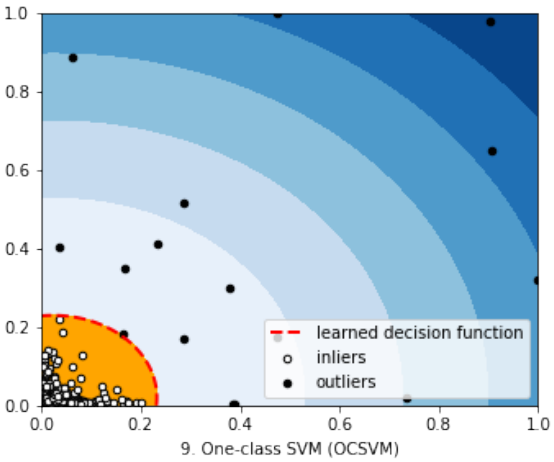

9. One-class SVM (OCSVM)

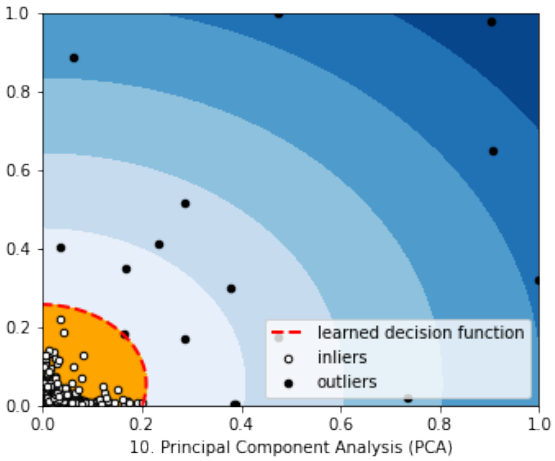

10. Principal Component Analysis (PCA)

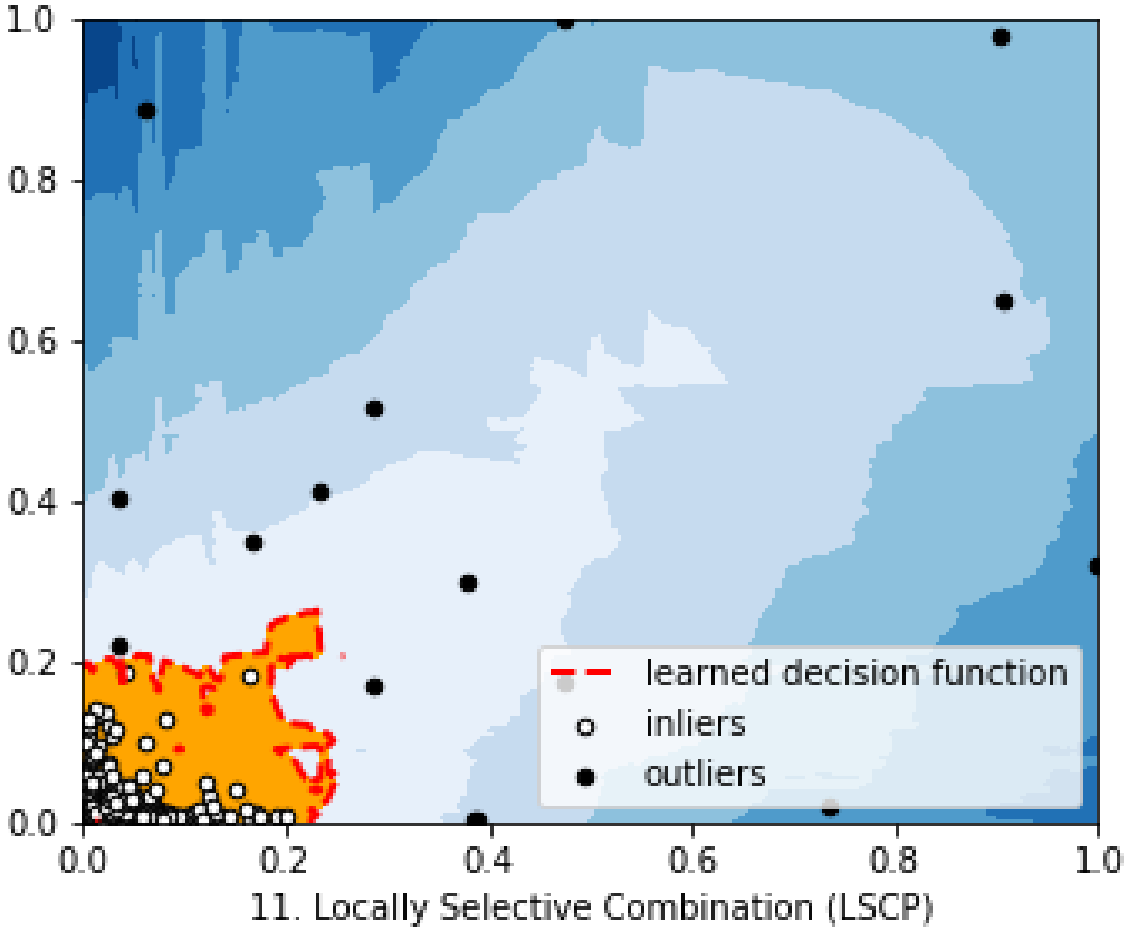

donde el número de OUTLIERS e INLIERS de cada uno son los siguientes:

```
OUTLIERS : 16 INLIERS : 1536 Angle-based Outlier Detector (ABOD)
OUTLIERS : 16 INLIERS : 1536 Cluster-based Local Outlier Factor (CBLOF)
OUTLIERS : 15 INLIERS : 1537 Histogram-base Outlier Detection (HBOS)
OUTLIERS : 16 INLIERS : 1536 Isolation Forest
OUTLIERS : 16 INLIERS : 1536 K Nearest Neighbors (KNN)
OUTLIERS : 15 INLIERS : 1537 Average KNN
OUTLIERS : 16 INLIERS : 1536 Local Outlier Factor (LOF)
OUTLIERS : 16 INLIERS : 1536 Minimum Covariance Determinant (MCD)
OUTLIERS : 16 INLIERS : 1536 One-class SVM (OCSVM)
OUTLIERS : 16 INLIERS : 1536 Principal Component Analysis (PCA)
OUTLIERS : 16 INLIERS : 1536 Locally Selective Combination (LSCP)
```

Vemos que en general, todos los algoritmos nos han proporcionado los mismos resultados, los contornos, outliers e inliers son muy parecidos.

Planteamiento de futuro

En los modelos que creamos anteriormente, usamos todo el conjunto de datos para entrenar nuestros algoritmos. En la práctica, no tenemos acceso a la información en el futuro (al menos no con la tecnología actual). Si tuvieramos más tiempo podríamos intentar realizar aprendizaje supervisado, aunque el problema de esto seria que tendríamos que etiquetar a mano cuales son las anomalías y ya clasificar con una clase outlier y otra de datos normales. El principal problema del área de conocimiento elegido es como hemos comentado en algún momento en el guión, y es que son procesos estocásticos, tenemos la variable del tiempo, si contamos los días como si no fuera importante estamos perdiendo un factor. También habría que tener más conocimiento sobre el área de estudio para definir bien que buscamos como outlier. En un par de busquedas por internet vemos que una buena solución que aplica la gente y especialistas del gremio es soluciones deep learning time-series data. [Sto]. Algorithmic trading ha revolucionado el mercado de valores y la industria que lo rodea. Más del 70% de todas las operaciones que se realizan en los EE. UU están hechas por bots [Nn]. Atrás quedaron los días de la bolsa de valores abarrotada con gente vestida agitando hojas de papel gritando en los teléfonos. Este tema me hace pensar en cómo podría desarrollar mi propio algoritmo para negociar acciones, o al menos tratar de predecirlas con precisión. Si pudiera dedicarle más tiempo al problema me gustaría estudiar deep learning para este tipo de problemas. Las finanzas son problemas no lineales y, a veces, los datos de precios de las acciones pueden incluso parecer completamente aleatorios. Los métodos tradicionales de time series como los modelos ARIMA, SARIMA y GARCH son efectivos solo cuando la serie es estacionaria, que es una suposición restrictiva que requiere que la serie sea preprocesada tomando retornos logarítmicos (u otras transformaciones). Sin embargo, el problema principal surge al implementar estos modelos en un sistema de comercio en vivo, ya que no hay garantía de estacionariedad a medida que se agregan nuevos datos. Eluso de redes neuronales (modelos secuenciales como LSTM, GRU, etc.), que no requieren ninguna estacionariedad para su uso parece la solución más adecuada. Además, las redes neuronales por naturaleza son efectivas para encontrar las relaciones entre los datos y usarlas para predecir (o clasificar) nuevos datos. Machine learning y deep learning han encontrado su lugar en las instituciones financieras por su poder para predecir datos de series de tiempo con altos grados de precisión y la investigación aún continúa para mejorar los modelos. Y aunque informes recientes sugieren que la inteligencia artificial ”descifrará el código” de los mercados financieros mediante el uso de big data y aprendizaje automático [Cra] no creo que haya un código que descifrar. Lo que sí existe es la

búsqueda constante de una “ventaja” sistemática en la que una máquina reconozca cuándo y cuánto riesgo tomar. Lo cuál me hace pensar que ahora mismo no hay un ”método” para prevenir la ”anomalía”, ya que si lo hubiera, se habría visto venir el acontecimiento comentado en el guión, pero al contrario esto ha pillado a todo wallstreet por sorpresa. Finalmente, de nuevo decir que si disponiera de más tiempo para dedicarle a este proyecto, me gustaría ver técnicas aplicadas de deep leraning a time series en problemas de este estilo y estudiar más a fondo porque no se puede predecir el valor de una acción.

Referencias

[Cra] *Can an artificial intelligence learn to beat the stock market?* visited on 29-01-2021. URL: https://www.fastcompany.com/90502428/artificial-intelligence-beat-the-stock-market.

[Pyoa] *Comparison alghoritms*. visited on 29-01-2021. URL: https://github.com/yzhao062/pyod/blob/master/notebooks/Compare%20All%20Models.ipynb.

[For] *How To Apply Anomaly Detection And Reap These Three Benefits*. visited on 27-01-2021. URL: https://www.forbes.com/sites/forbesagencycouncil/2020/02/03/how-to-apply-anomaly-detection-and-reap-these-three-benefits/#5a289a5114bf.

[Ter] *La noche de los 40 terremotos en Granada*. visited on27-01-2021. URL: https://elpais.com/espana/2021-01-27/la-noche-de-los-40-terremotos-en-granada-ibamos-buscando-espacios-sin-arboles-ni-edificios.html.

[Nn] *NN in finances*. visited on 29-01-2021. URL: https://medium.com/analytics-vidhya/introduction-to-neural-networks-for-finance-6abd5675e497.

[Pan] *Pandas Datareader*. visited on 27-01-2021. URL: https://pandas-datareader.readthedocs.io/en/latest/.

[Pyob] *PyOD*. visited on 27-01-2021. URL: https://github.com/yzhao062/pyod/.

[Lis] *PyOD models*. visited on 28-01-2021. URL: https://github.com/yzhao062/pyod#implemented-algorithms.

[Red] *Reddit group blew up GameStop stock*. visited on 27-01-2021. URL: https://edition.cnn.com/2021/01/27/investing/gamestop-reddit-stock/index.html.

[Pic] *Reddit Pictoline*. visited on 28-01-2021. URL: https://www.pictoline.com/timeline/2021/01/28/15hrs26min02sec.

[Cal] *Reddit user*. visited on 26-01-2021. URL: https://www.reddit.com/r/wallstreetbets/comments/l5nphz/gme_yolo_update_jan_26_2021/.

[Skl] *Scikit-Learn Outlier Detection*. visited on 27-01-2021. URL: https://scikit-learn.org/stable/modules/outlier_detection.html.

[Sto] *Stock market anomalies*. visited on 29-01-2021. URL: https://towardsdatascience.com/stock-market-anomalies-and-stock-market-anomaly-detection-are-two-different-things-624331c7b65a.